

# Tablosal Veride Dağılım Kaymasına Duyarlı Güvenilirlik İzleme: Güven, Kalibrasyon, Veri Kayması ve Açıklama Sinyallerinin Erken Uyarı Performansının Karşılaştırmalı Analizi

Proje türü: Grup Projesi | Üyeler: Zehra Akgül (241230036), Elif Su Baydarlı (241230017) | Ders: Uygulamalı Yapay Zekâ

**Özet.** Dağıtılmış bir makine öğrenmesi modelinin doğruluğu, etiketler gecikmeli geldiği için çoğu zaman gerçek zamanlı ölçülemez. Bu çalışma, gerçek tablosal veri kümelerinden üretilen kontrollü bir kayma benchmarkı üzerinde, etiketsiz izleme sinyallerinin (güven, kalibrasyon, veri kayması, açıklama kayması) performans çöküşünü ne kadar erken ve doğru işaretlediğini sistematik biçimde karşılaştırır ve bulgulara dayanan, kayma türüne duyarlı bir güvenilirlik izleme protokolü önerir.

## 1. Problemin Tanımı

Model başarımı genellikle eğitim ve test verisinin aynı dağılımdan geldiği varsayımıyla Accuracy, F1 veya AUC ile raporlanır. Dağıtım sonrasında kullanıcı davranışı, ekonomik koşullar veya veri toplama süreci değiştiğinde bu varsayım bozulur (distribution shift) [13]. Kredi, sağlık ve dolandırıcılık gibi alanlarda asıl risk, performans düştüğünde geç kalmak ve modelin yanlış fakat yüksek güvenle karar vermesidir. Amaç yeni bir sınıflandırıcı geliştirmek değil, mevcut bir modelin ne zaman artık güvenilmemesi gerektiğini performans çökmeden önce anlamaktır. Araştırma sorusu: Farklı kayma mekanizmalarında hangi etiketsiz izleme sinyali performans bozulmasını en erken ve en az yanlış alarmla yakalar ve sinyaller kayma türüne göre nasıl birleştirilmelidir? Alt sorular: (RQ1) Erken uyarı süresi kayma türüne göre nasıl değişir? (RQ2) SHAP tabanlı açıklama kayması, permütasyon temelli gerçek özellik bağımlılığıyla ne zaman uyuşmaz ve bu uyuşmazlık uyarı değeri taşır mı? (RQ3) Kayma türüne duyarlı çoklu sinyal birleşimi, tek sinyalli ve sabit formüllü izlemeyi geçer mi? Bu belge bir proje önerisidir; henüz deney yapılmamış ve sonuç elde edilmemiştir. Sınanacak hipotezler: H1: gürültü/eksik veride güven ve kalibrasyon sinyalleri, veri kayması sinyallerinden önce uyarır; H2: kavram ve kısayol kaymasında girdi dağılımı sabit kaldığından veri kayması sinyalleri başarısız olur, açıklama-bağımlılık uyuşmazlığı daha bilgilidir; H3: kayma-farkında birleşim, en iyi tek sinyale göre erken uyarıda anlamlı üstünlük sağlar.

## 2. Veri Setleri ve Kontrollü Benchmark

Birincil veri kaynağı, ABD Nüfus Sayımı Bürosu ACS verisinden türetilen ve yıl ile eyalet bazlı doğal zamansal/coğrafi kayma içeren Folktables görevleridir (ACSIIncome, ACSEmployment) [7]. Dış doğrulama için TableShift benchmarkından en az iki görev kullanılacaktır [5] (kodlar: <https://github.com/socialfoundations/folktables> ve <https://github.com/mlfoundations/tableshift>). Mevcut benchmarklar çoğunlukla tek bir doğal kayma tanımlar [5], [6], [14]; biz aynı kaynak veriden altı kayma mekanizmasını ve her biri için artan şiddet düzeylerini kendi kontrollü enjeksiyon kodumuzla üreteceğiz (Tablo 1). Sınıflandırıcılar: Lojistik Regresyon, Random Forest ve XGBoost/LightGBM; ağaç tabanlı modellerin tablosal veride güçlü olması bu seçimi gerekçelendirir [12]. Veri sayıları, indirilen sürümde Faz 1'de doğrulanıp raporlanacaktır.

Tablo 1. Planlanan kontrollü kayma senaryoları

| Kayma türü                 | Kontrollü üretim yöntemi                                                                 | Şiddet eksen                         |
|----------------------------|------------------------------------------------------------------------------------------|--------------------------------------|
| Özellik (kovaryat) kayması | Seçili özelliklerin ortalama/varyans ve alt-grup oranlarının yeniden örneklenmesi        | Standart ortalama farkı (SMD)        |
| Eksik veri                 | MCAR/MAR maskeleyme + basit imputation                                                   | %5, 10, 20, 30                       |
| Gürültü                    | Sayısal özelliklere Gauss, kategoriklere etiket çevirme                                  | $\sigma = 0,1-1,0 \times \text{std}$ |
| Zamansal / coğrafi         | ACS yıllarında (2014→2018) ve eyaletler arası eğitim-test ayrımı                         | Yıl / eyalet uzaklığı                |
| Kavram kayması $P(Y X)$    | Alt uzayda karar kuralının kısmi tersine çevrilmesi; doğal ACS kaymaları                 | Etkilenen oran $\alpha$              |
| Kısayol (spurious) kayması | Eğitimde etiketle $\rho \approx 0,9$ ilişkili sahte özellik; testte $\rho \rightarrow 0$ | $\rho: 0,9 \rightarrow 0$            |

## 3. Literatür Taraması ve Araştırma Boşluğu

Rabanser ve ark. [1], veri kayması tespiti için yöntemleri karşılaştırmış; önceden eğitilmiş sınıflandırıcıyla boyut indirgeme sonrası iki-örneklem testinin en iyi sonucu verdiğini bildirmiştir. Ovadia ve ark. [2], kayma şiddeti arttıkça tahmin belirsizliği ve kalibrasyon kalitesinin bozulduğunu göstermiş; Guo ve ark. [3] modern sinir ağlarının yanlış kalibre olabildiğini ortaya koymuştur. Garg ve ark. [8], etiketsiz veride model güvenine dayanarak dağıtım dışı doğruluğu tahmin etmiştir. Mougan ve ark. [4], tablosal veride açıklama uzayındaki

kaymanın, girdi dağılımı kaymasına dayalı yöntemlere göre performans değişimini daha iyi gösterebildiğini bildirmiştir. Gardner ve ark. [5], 15 görevli TableShift benchmarkında dağıtım içi ve dışı doğruluk arasında doğrusal bir eğilim ile kayma farkının etiket dağılımı kaymasıyla güçlü ilişkisini göstermiş; Liu ve ark. [6] ise tablosal verilerde  $P(Y|X)$  kaymalarının yaygın olduğunu ve mevcut benchmarkların ağırlıkla  $X$ -kaymalarına odaklandığını vurgulamıştır. Kısayol öğrenme güvenilir genellemenin başlıca nedenlerinden biridir [11]. SHAP [9] ve permütasyon tabanlı model bağımlılığı [10] ayrı ayrı yaygın olsa da, taradığımız çalışmalarda şu üçlü bir arada sistematik biçimde ele alınmamıştır: (i) birden fazla kayma mekanizması, (ii) etiketsiz sinyallerin erken uyarı süresi ve yanlış alarm oranı, (iii) açıklama ile gerçek özellik bağımlılığı arasındaki tutarsızlığın uyarı değeri. Bu boşluğu, yazım öncesi en yakın 15–20 çalışmayla hazırlanacak bir yenilik matrisiyle doğrulayacağız; “hiç yapılmamış” iddiasında bulunmuyoruz.

#### 4. Planlanan Yöntem ve Özgünlük

**Sinyaller.** (a) Performans (referans): Accuracy, F1, AUC. (b) Güven: ortalama maksimum olasılık, entropi, güven dağılımı kayması. (c) Kalibrasyon: ECE ve Brier skoru; etiket gerektirdiği için “gecikmeli etiket” referansı olarak ayrı raporlanacak. (d) Veri kayması: PSI, KS/Wasserstein ve alan ayırt edici sınıflandırıcı AUC’si. (e) Açıklama kayması: TreeSHAP/LinearSHAP ortalama  $|\phi|$  vektörünün kayması ve Explanation Shift Detector [4]. (f) Özellik bağımlılığı: permütasyon önemi [10]; SHAP ile permütasyon sıralaması arasındaki Spearman korelasyonunun düşüşü “açıklama–bağımlılık uyumsuzluğu” sinyali olarak tanımlanacaktır.

**Erken uyarı ölçümü.** Her kayma türü için şiddet eksenini boyunca, performansın göreceli olarak  $\delta$  (ör. %5) düşmesi “bozulma olayı” sayılır. Her sinyalin eşiği, dağıtım içi bootstrap örneklerinde %5 yanlış alarm oranına göre sabitlenir. Metrikler: bozulma tespiti AUROC’si, uyarı önceliği (bozulmadan kaç şiddet adımı önce alarm) ve yanlış alarm oranı. Deneyler çoklu rastgele tohum, üç model ve bootstrap güven aralıklarıyla tekrarlanacak; sinyaller arası fark için eşleşmiş testler (Wilcoxon) ve çoklu karşılaştırma düzeltmesi kullanılacak,  $\delta$  ve eşik duyarlılık analizi yapılacaktır.

**Uyarlanabilir protokol.** Sinyal vektöründen kayma türünü tahmin eden küçük bir meta-model ve türe göre sinyal ağırlıkları öğrenilecek; çıktı yeşil (güvenilir), sarı (izlenmeli) ve kırmızı (yeniden değerlendirme gerekli) olacaktır. Doğrulama “bir kayma türü dışarıda bırakılır” (leave-one-shift-out) ve “bir veri seti dışarıda bırakılır” şemasıyla yapılacak; taban çizgileri: tek sinyalli izleme, sabit ağırlıklı birleşim, BBSO tabanlı tespit [1], güven tabanlı tahmin [8] ve açıklama kayması [4].

**Özgünlük ve sınırlılık.** SHAP, kalibrasyon veya veri kayması ölçmenin kendisi özgün değildir. Katkımız: (1) altı kayma mekanizmasını aynı protokolde kıyaslayan, tekrarlanabilir açık kaynak bir benchmark; (2) sinyallerin erken uyarı süresi ve yanlış alarm dengesine dair kayma türüne özgü ampirik bulgular; (3) açıklama–bağımlılık uyumsuzluğunun uyarı değerinin test edilmesi; (4) bulgulardan türetilen, dışarıda bırakma ile doğrulanan kayma-farkında izleme protokolü. Sonuçlar baştan varsayılmayacak, negatif bulgular da raporlanacaktır. Benchmark sentetik enjeksiyonlar içerdiğinden, doğal ACS ve TableShift kaymalarıyla çapraz doğrulama yapılacaktır.

#### Kaynakça

- [1] S. Rabanser, S. Günnemann, and Z. C. Lipton, “Failing loudly: An empirical study of methods for detecting dataset shift,” in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 32, 2019. <https://doi.org/10.48550/arXiv.1810.11953>
- [2] Y. Ovadia et al., “Can you trust your model’s uncertainty? Evaluating predictive uncertainty under dataset shift,” in *NeurIPS*, vol. 32, 2019. <https://doi.org/10.48550/arXiv.1906.02530>
- [3] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, “On calibration of modern neural networks,” in *Proc. ICML*, PMLR 70, 2017, pp. 1321–1330. <https://doi.org/10.48550/arXiv.1706.04599>
- [4] C. Mougan, K. Broelemann, G. Kasneci, T. Tiropanis, and S. Staab, “Explanation shift: Detecting distribution shifts on tabular data via the explanation space,” *NeurIPS 2022 Workshop on Distribution Shifts*. <https://doi.org/10.48550/arXiv.2210.12369>
- [5] J. Gardner, Z. Popovic, and L. Schmidt, “Benchmarking distribution shift in tabular data with TableShift,” *NeurIPS 2023 Datasets and Benchmarks Track*. <https://doi.org/10.48550/arXiv.2312.07577>
- [6] J. Liu, T. Wang, P. Cui, and H. Namkoong, “On the need for a language describing distribution shifts: Illustrations on tabular datasets,” *NeurIPS 2023 Datasets and Benchmarks Track*. <https://doi.org/10.48550/arXiv.2307.05284>
- [7] F. Ding, M. Hardt, J. Miller, and L. Schmidt, “Retiring Adult: New datasets for fair machine learning,” in *NeurIPS*, vol. 34, 2021. <https://doi.org/10.48550/arXiv.2108.04884>
- [8] S. Garg, S. Balakrishnan, Z. C. Lipton, B. Neyshabur, and H. Sedghi, “Leveraging unlabeled data to predict out-of-distribution performance,” in *Proc. ICLR*, 2022. <https://doi.org/10.48550/arXiv.2201.04234>
- [9] S. M. Lundberg and S.-I. Lee, “A unified approach to interpreting model predictions,” in *NeurIPS*, vol. 30, 2017. <https://doi.org/10.48550/arXiv.1705.07874>

- [10] A. Fisher, C. Rudin, and F. Dominici, “All models are wrong, but many are useful: Learning a variable's importance by studying an entire class of prediction models simultaneously,” *J. Mach. Learn. Res.*, vol. 20, no. 177, pp. 1–81, 2019. <https://jmlr.org/papers/v20/18-760.html>
- [11] R. Geirhos et al., “Shortcut learning in deep neural networks,” *Nat. Mach. Intell.*, vol. 2, no. 11, pp. 665–673, 2020. <https://doi.org/10.1038/s42256-020-00257-z>
- [12] L. Grinsztajn, E. Oyallon, and G. Varoquaux, “Why do tree-based models still outperform deep learning on typical tabular data?,” *NeurIPS 2022 Datasets and Benchmarks Track*. <https://doi.org/10.48550/arXiv.2207.08815>
- [13] J. Gama, I. Žliobaitė, A. Bifet, M. Pechenizkiy, and A. Bouchachia, “A survey on concept drift adaptation,” *ACM Comput. Surv.*, vol. 46, no. 4, art. 44, 2014. <https://doi.org/10.1145/2523813>
- [14] P. W. Koh et al., “WILDS: A benchmark of in-the-wild distribution shifts,” in *Proc. ICML*, PMLR 139, 2021. <https://doi.org/10.48550/arXiv.2012.07421>